

REGRESIÓN LINEAL MÚLTIPLE Y POLINOMIAL

Informe Técnico Consolidado

Caso 3 — Diabetes · Regresión Lineal Múltiple y Regresión Polinomial

Dataset	sklearn.datasets.load_diabetes (442 muestras, 10 variables)
Contexto	Progresión cuantitativa de la enfermedad un año después del inicio
Metodología	Regresión Lineal Múltiple y Regresión Polinomial
Partición	75 % entrenamiento / 25 % prueba (random_state = 42)
Herramientas	Python 3.13 · scikit-learn 1.9 · pandas · NumPy · SciPy · Matplotlib
Reproducción	python train.py

INTEGRANTES Y DIVISIÓN DE FUNCIONES

Integrante	Función desempeñada

(completar antes de la entrega)

Tabla de contenido

Estructura de la documentación 3

Síntesis por fases 3

 Fase A — Análisis exploratorio y preprocesamiento..... 3

 Fase B — Modelamiento y comparativa 3

 Fase C — Aplicativo web 4

Comparativa global entre metodologías..... 4

 Modelo recomendado: Regresión Lineal Múltiple (OLS, 10 variables) 4

Conclusiones técnicas 4

Estructura de carpetas y archivos entregados 5

Referencias..... 5

Para actualizar el índice en Word: clic derecho sobre él → Actualizar campos → Actualizar toda la tabla.

Estructura de la documentación

Las dos metodologías exigidas se documentan **por separado**, cada una en su propio informe autocontenido:

Documento	Contenido
Informe 1 — Regresión Lineal Múltiple	Fase A completa (EDA y preprocesamiento) + Fase B múltiple (OLS, Ridge, Lasso, significancia, residuos) + Fase C
Informe 2 — Regresión Polinomial	Fase A resumida + Fase B polinomial (grados 1–3, análisis de sobreajuste, comparativa) + Fase C
Este documento	Síntesis, comparativa global y conclusiones conjuntas

La **Fase A es común** a ambas metodologías y se desarrolla íntegra en el Informe 1; el Informe 2 incluye el resumen necesario para ser leído de forma independiente.

Síntesis por fases

Fase A — Análisis exploratorio y preprocesamiento

Requisito	Resultado
Dimensiones	442 × 10, todas float64
Limpieza / nulos	0 nulos, 0 duplicados → no se requiere imputación
Outliers	2 a 9 por variable (IQR); ninguno en el target . Se conservan: control winsorizado 1–99 % mueve el R^2 solo +0.0016
Multicolinealidad	Severa y estructural . VIF: s1 59.20, s2 39.19, s3 15.40, s5 10.08. $r(\mathbf{s1}, \mathbf{s2}) = \mathbf{+0.897}$
Estandarización	StandardScaler dentro del Pipeline (evita fuga de información en la validación cruzada)
Partición	331 entrenamiento / 111 prueba (75 / 25)

Causa de la multicolinealidad: **s4** = **s1/s3** por definición y **s2** (LDL) es un componente de **s1** (colesterol total). No es casual, es una dependencia algebraica.

Fase B — Modelamiento y comparativa

Modelo	Términos	R^2 entren.	R^2 prueba	R^2 CV 5-fold
Lineal múltiple — OLS	10	0.5190	0.4849	0.4606 ± 0.085
Lineal — sin s1,s2 (VIF)	8	0.5078	0.4964	0.4504
Lineal — Ridge ($\alpha = 1.59$)	10	0.5185	0.4862	0.4597
Lineal — Lasso ($\alpha = 0.114$)	10	0.5185	0.4868	0.4577
Polinomial gr. 2 — sin regularizar	65	0.6048	0.4242	0.2979
Polinomial gr. 2 — Ridge ($\alpha = 25.12$)	65	0.5373	0.4911	0.4611 ± 0.083
Polinomial gr. 3 — sin regularizar	285	0.8960	-8.0873	-171.12
Polinomial gr. 3 — Ridge ($\alpha = 199.53$)	285	0.5361	0.4942	0.4603

Fase C — Aplicativo web

`index.html` + `model.js`, en HTML y JavaScript puro, sin dependencias ni build. Incorpora **ambos modelos con un selector**, entrada dinámica de las 10 variables, cálculo paso a paso y las tablas de resultados de las Fases A y B.

Paridad con scikit-learn verificada con precisión de punto flotante en los dos modelos (p. ej. medianas del dataset: Python `155.862491` → JavaScript `155.8624910825692`).

Comparativa global entre metodologías

	Lineal Múltiple	Polinomial gr. 2 + Ridge
Términos	10	65
R ² validación cruzada	0.4606	0.4611
Desviación entre particiones	±0.085	±0.083
Brecha entrenamiento – CV	0.058	0.076
RMSE / MAE prueba	53.37 / 41.55	53.05 / 41.59
Coefficientes interpretables	Sí	No
Depende de hiperparámetro	No	Sí (α)

La diferencia en validación cruzada es de **+0.0005**, frente a una desviación entre particiones de **±0.083**: la ventaja aparente es **166 veces menor que el ruido de la propia medición**. Los modelos son **estadísticamente indistinguibles**.

Modelo recomendado: Regresión Lineal Múltiple (OLS, 10 variables)

Por el principio de parsimonia: mismo rendimiento con seis veces menos parámetros, coeficientes interpretables, menor brecha train-CV y sin dependencia de un hiperparámetro que calibrar.

Conclusiones técnicas

- 1. El dataset es adecuado** para ambas metodologías: variable objetivo continua, 10 predictores numéricos, sin nulos ni duplicados. Se usó `scaled=False` para poder aplicar el preprocesamiento exigido y construir una interfaz con unidades clínicas reales.
- 2. La multicolinealidad estructural es el hallazgo dominante de la Fase A** y condiciona ambas metodologías. En la múltiple infla los errores estándar entre 5 y 7 veces (`s1`: 22.21 frente a 3.32 de `age`), dejando los coeficientes lipídicos sin interpretación individual. En la polinomial explica por qué la expansión no aporta: genera términos redundantes a partir de variables ya redundantes.
- 3. La regularización es innecesaria en la múltiple e imprescindible en la polinomial.** Con 10 variables y 331 muestras no hay margen para sobreajustar, y Ridge/Lasso no mueven las métricas. Sobre 65 o 285 términos, en cambio, evitan el colapso del modelo.
- 4. El sobreajuste quedó cuantificado de forma inequívoca.** El polinomial de grado 3 sin regularizar alcanza el **mejor R² de entrenamiento del estudio (0.8960)** y es el **peor modelo de todos** fuera de la muestra (R² de prueba -8.09, CV -171.12). Es el argumento central contra evaluar un modelo por su ajuste en entrenamiento.
- 5. La relación es esencialmente lineal en el rango observado.** Dos análisis independientes coinciden: el diagnóstico de residuos del modelo lineal no muestra patrón estructural, y la expansión polinomial no encuentra nada que capturar.

- 6. El techo de $R^2 \approx 0.46\text{--}0.49$ proviene de los datos, no del modelo.** Son 442 pacientes y 10 variables basales, sin información sobre genética, tratamiento, adherencia, dieta ni comorbilidades. La literatura original de Efron et al. trabaja en este mismo rango. Aumentar la complejidad del modelo no puede compensar una carencia de información.
- 7. La validación cruzada fue determinante.** Escogiendo por R^2 de prueba se habría seleccionado el modelo sin **s1,s2** (0.4964) o el polinomial de grado 3 con Ridge (0.4942); la CV demuestra que ninguna de esas diferencias supera el ruido de muestreo con 111 muestras de prueba.

Estructura de carpetas y archivos entregados

El caso se organiza en **dos carpetas, una por metodología**, cada una autocontenida y ejecutable de forma independiente:

CASO_3/	
— index.html	• portada del caso, enlaza ambas metodologías
— INFORME_CONSOLIDADO.docx / .pdf	• este documento
— INFORME.md	• fuente Markdown del consolidado
— PLAN.md	• planificación y evaluación del dataset
— md_a_docx.py	• conversor de Markdown a Word
— 1_REGRESION_MULTIPLE/	
— train.py	• Fases A y B, exporta el modelo
— model.js	• 10 coeficientes + intercepto
— index.html	• aplicativo web interactivo
— resultados.json	• métricas en formato legible por máquina
— INFORME_1_REGRESION_MULTIPLE.docx / .pdf / .md	• 7 gráficos (boxplots, correlación, VIF, residuos, real vs. predicho, coeficientes)
— figuras/	
— 2_REGRESION_POLINOMIAL/	
— train.py	• Fases A y B, exporta el modelo
— model.js	• 65 términos + exponentes de la expansión
— index.html	• aplicativo web interactivo
— resultados.json	• métricas en formato legible por máquina
— INFORME_2_REGRESION_POLINOMIAL.docx / .pdf / .md	• 3 gráficos (correlación, curva de validación, brecha entrenamiento-validación)
— figuras/	

Cada carpeta se reproduce por completo con:

```
python train.py
```

Los aplicativos se sirven por HTTP (el `<script src="model.js">` no carga bajo `file://` en algunos navegadores):

```
python -m http.server 8000
```

Referencias

1. Efron, B., Hastie, T., Johnstone, I. y Tibshirani, R. (2004). *Least Angle Regression*. **Annals of Statistics**, 32(2), 407–499. https://web.stanford.edu/~hastie/Papers/LARS/LeastAngle_2002.pdf
2. Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. **Journal of Machine Learning Research**, 12, 2825–2830.
3. Documentación de scikit-learn — `sklearn.datasets.load_diabetes`. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_diabetes.html
4. James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning*, 2.ª ed. Springer.
5. Montgomery, D. C., Peck, E. A. y Vining, G. G. (2021). *Introduction to Linear Regression Analysis*, 6.ª ed. Wiley.

6. Fuente original de los datos: <https://www4.stat.ncsu.edu/~boos/var.select/diabetes.html>