

REGRESIÓN LINEAL MÚLTIPLE Y POLINOMIAL

Informe 1 — Regresión Lineal Múltiple

Caso 3 — Diabetes · Fases A, B y C

Dataset	sklearn.datasets.load_diabetes (442 muestras, 10 variables)
Contexto	Progresión cuantitativa de la enfermedad un año después del inicio
Metodología	Regresión Lineal Múltiple y Regresión Polinomial
Partición	75 % entrenamiento / 25 % prueba (random_state = 42)
Herramientas	Python 3.13 · scikit-learn 1.9 · pandas · NumPy · SciPy · Matplotlib
Reproducción	python train.py

INTEGRANTES Y DIVISIÓN DE FUNCIONES

Integrante	Función desempeñada

(completar antes de la entrega)

Tabla de contenido

Resumen ejecutivo	3
FASE A — Análisis exploratorio y preprocesamiento	4
A.0 Carga del dataset y decisión sobre la escala	4
A.1 Tipos de datos, valores nulos y duplicados	4
Resultado de la limpieza	4
Recodificación de la variable categórica	5
A.2 Tratamiento de outliers	5
Decisión: se conservan. Justificación cuantitativa	6
A.3 Análisis de multicolinealidad	6
Matriz de correlación de Pearson	6
Factor de Inflación de la Varianza (VIF)	7
Interpretación: la multicolinealidad es estructural, no casual	7
A.4 Estandarización	8
A.5 Partición de datos	8
FASE B — Regresión Lineal Múltiple	9
B.1 Formulación del modelo	9
B.2 Variantes entrenadas y resultados	9
Lecturas	9
B.3 Significancia estadística de los coeficientes	9
Confirmación numérica del diagnóstico de la Fase A	10
B.4 Diagnóstico de residuos	11
B.5 Sobre la precisión alcanzada	12
FASE C — Aplicativo web (modo Regresión Lineal Múltiple)	14
Funcionalidades relevantes a este informe	14
Verificación de paridad con scikit-learn	14
Ejecución y despliegue	14
Conclusiones — Regresión Lineal Múltiple	15
Referencias	16

Para actualizar el índice en Word: clic derecho sobre él → Actualizar campos → Actualizar toda la tabla.

Este informe cubre **exclusivamente la Regresión Lineal Múltiple**. La Regresión Polinomial se documenta en [INFORME_2_REGRESION_POLINOMIAL .md](#). La Fase A es común a ambas metodologías y se desarrolla completa aquí.

Resumen ejecutivo

Metodología	Regresión Lineal Múltiple (OLS, Ridge, Lasso)
Muestras	442 (331 entrenamiento / 111 prueba)
Variables	10 predictoras, todas numéricas
Modelo final	OLS con las 10 variables
R ² entrenamiento	0.5190
R ² prueba	0.4849
R ² validación cruzada 5-fold	0.4606 ± 0.085
RMSE / MAE prueba	53.37 / 41.55 puntos
Brecha entrenamiento – CV	0.0584 → sin sobreajuste
Predictores significativos	bmi, s5, bp, sex, s1

FASE A — Análisis exploratorio y preprocesamiento

A.0 Carga del dataset y decisión sobre la escala

```
X, y = load_diabetes(return_X_y=True, as_frame=True, scaled=False)
```

`load_diabetes()` devuelve por defecto (`scaled=True`) los datos **ya centrados y escalados** por la desviación estándar $\times \sqrt{n}$, con valores adimensionales en el rango -0.14 a 0.20 . Se usó `scaled=False` de forma deliberada, por dos razones:

1. La Fase A exige aplicar `StandardScaler/MinMaxScaler`; no tiene sentido estandarizar datos ya estandarizados, y el procedimiento no sería demostrable.
2. La Fase C exige que el usuario ingrese parámetros. Un usuario introduce "IMC = 26.4", no "IMC = 0.0507".

A.1 Tipos de datos, valores nulos y duplicados

442 filas $\times$ 10 columnas. **Todas de tipo float64.**

Variable	Descripción	Unidad	Media	Desv.	Mín	Máx
age	Edad	años	48.52	13.11	19.0	79.0
sex	Sexo (categórica binaria)	0 / 1	0.47	0.50	0	1
bmi	Índice de masa corporal	kg/m ²	26.38	4.42	18.0	42.2
bp	Presión arterial media	mm Hg	94.65	13.83	62.0	133.0
s1	Colesterol total (tc)	mg/dL	189.14	34.61	97.0	301.0
s2	Lipoproteínas LDL (ldl)	mg/dL	115.44	30.41	41.6	242.4
s3	Lipoproteínas HDL (hdl)	mg/dL	49.79	12.93	22.0	99.0
s4	Razón colesterol total / HDL (tch)	ratio	4.07	1.29	2.0	9.09
s5	Triglicéridos séricos, <i>posiblemente</i> en log (ltg)	log	4.64	0.52	3.26	6.11
s6	Glucosa en sangre (glu)	mg/dL	91.26	11.50	58.0	124.0

Nota sobre s1–s6: los nombres provienen del `.DESCR` oficial. La propia documentación de scikit-learn advierte que su significado exacto *"puede no ser claro, especialmente para Ltg"*, porque el dataset original no lo documenta de forma explícita. Se reporta con esa reserva.

Variable objetivo: medida cuantitativa de progresión de la enfermedad a un año. Continua, rango 25 – 346, media 152.13, **asimetría 0.441**.

Resultado de la limpieza

Verificación	Resultado	Acción
Valores nulos	0	No se requiere imputación
Filas duplicadas	0	No se requiere deduplicación
Asimetría del target	0.441 (aceptable)	No se aplica transformación logarítmica

La ausencia de nulos se verificó explícitamente (`.isna().sum()`, `.duplicated().sum()`) y se documenta para dejar constancia de que la comprobación se realizó.

Recodificación de la variable categórica

sex es la única variable categórica y viene codificada como 1/2. Se recodificó a **0/1** para que su coeficiente se interprete como el efecto de una categoría respecto a la otra. No debe leerse como una variable continua.

A.2 Tratamiento de outliers

Detección por el método del rango intercuartílico (IQR, $k = 1.5$):

Variable	Outliers	%
s6	9	2.0 %
s1	8	1.8 %
s2	7	1.6 %
s3	7	1.6 %
s5	4	0.9 %
bmi	3	0.7 %
s4	2	0.5 %
target	0	—




Figura. Diagramas de caja por variable (método IQR)




Figura. Distribución y gráfico Q-Q de la variable objetivo

Decisión: se conservan. Justificación cuantitativa

Los valores atípicos son **clínicamente plausibles** — un colesterol total de 301 mg/dL es alto, pero perfectamente real en una población diabética — y con solo 442 muestras cada observación es valiosa. La variable objetivo no presenta outliers.

Para no dejar la decisión en lo cualitativo, se entrenó un modelo de control con los datos **winsorizados a los percentiles 1–99**:

Tratamiento	R ² prueba
Sin tratar outliers	0.4849
Winsorizado 1 % – 99 %	0.4865
Diferencia	+0.0016

La mejora es despreciable frente a la desviación de la validación cruzada (± 0.085). **Se confirma la decisión de conservarlos.**

A.3 Análisis de multicolinealidad

Matriz de correlación de Pearson




Figura. Matriz de correlación de Pearson

Pares con $|r| > 0.5$:

Par	r
s1 – s2	+0.897
s3 – s4	-0.738
s2 – s4	+0.660
s4 – s5	+0.618
s1 – s4	+0.542
s1 – s5	+0.516

Factor de Inflación de la Varianza (VIF)

Calculado como $VIF_j = 1 / (1 - R_j^2)$, donde R_j^2 es el ajuste de la variable j regresada contra todas las demás.




Figura. Factor de Inflación de la Varianza (VIF)

Variable	VIF	Diagnóstico
s1	59.20	Severa
s2	39.19	Severa
s3	15.40	Severa
s5	10.08	Severa
s4	8.89	Moderada
bmi	1.51	Aceptable
s6	1.48	Aceptable
bp	1.46	Aceptable
sex	1.28	Aceptable
age	1.22	Aceptable

Interpretación: la multicolinealidad es estructural, no casual

No se trata de una correlación fortuita, sino de una **dependencia por definición**:

- s_4 = colesterol total / HDL = s_1 / s_3 . Es literalmente un cociente de otras dos variables del conjunto.
- s_2 (LDL) es un **componente** de s_1 (colesterol total), que agrupa LDL + HDL + otras fracciones.

Las cinco variables lipídicas (s_1 – s_5) describen el mismo perfil desde ángulos solapados. **Consecuencia práctica:** sus coeficientes individuales no son interpretables por separado, porque el modelo no puede atribuir el efecto a una u otra. Esto se confirma numéricamente en la sección B.2 de este informe.

Las variables clínicamente independientes (age , sex , bmi , bp , s_6) tienen VIF por debajo de 1.6, es decir, sin problema alguno.

A.4 Estandarización

Se aplicó **StandardScaler** (media 0, desviación 1) **dentro de un Pipeline de scikit-learn:**

```
Pipeline([("sc", StandardScaler()), ("lr", LinearRegression())])
```

Esto es esencial y no meramente cosmético: al estar dentro del **Pipeline**, la media y la desviación se recalculan **con los datos de entrenamiento de cada partición** en la validación cruzada. Si se estandarizara todo el conjunto antes de partirlo, la información del set de prueba se filtraría al entrenamiento (*data leakage*) y las métricas quedarían infladas.

Se eligió **StandardScaler** sobre **MinMaxScaler** porque la regresión con regularización (Ridge/Lasso) penaliza la magnitud de los coeficientes, y esa penalización solo es equitativa si todas las variables comparten escala de varianza.

A.5 Partición de datos

	Muestras	Proporción
Entrenamiento	331	75 %
Prueba	111	25 %

```
train_test_split(X, y, test_size=0.25, random_state=42).
```

Advertencia metodológica. Con solo 111 muestras de prueba, el R^2 de test es una medida ruidosa: reordenar la partición puede moverlo varias centésimas. Por eso **todas las comparaciones se hacen sobre la validación cruzada 5-fold** del set de entrenamiento, reportando además su desviación estándar. El R^2 de prueba se incluye únicamente como comprobación final independiente.

FASE B — Regresión Lineal Múltiple

B.1 Formulación del modelo

La regresión lineal múltiple modela la variable objetivo como combinación lineal de los p predictores:

$$\hat{y} = \beta_0 + \beta_1 z_1 + \beta_2 z_2 + \dots + \beta_{10} z_{10} \quad \text{con } z_i = (x_i - \mu_i) / \sigma_i$$

Los coeficientes se estiman por **mínimos cuadrados ordinarios (OLS)**, minimizando la suma de residuos al cuadrado:

$$J(\beta) = \sum_j (y_j - \hat{y}_j)^2$$

Las variantes regularizadas añaden una penalización sobre la magnitud de los coeficientes:

$$\begin{aligned} \text{Ridge (L2): } J(\beta) &= \sum_j (y_j - \hat{y}_j)^2 + \alpha \cdot \sum \beta_i^2 \\ \text{Lasso (L1): } J(\beta) &= \sum_j (y_j - \hat{y}_j)^2 + \alpha \cdot \sum |\beta_i| \end{aligned}$$

En ambos casos α se seleccionó por validación cruzada 5-fold (**RidgeCV**, **LassoCV**).

B.2 Variantes entrenadas y resultados

Cuatro variantes, todas con **StandardScaler** dentro del **Pipeline**:

Modelo	Términos	R ² entren.	R ² prueba	R ² CV 5-fold	Brecha train-CV
OLS — 10 variables	10	0.5190	0.4849	0.4606 ± 0.085	0.0584
OLS — sin s1,s2 (corte por VIF)	8	0.5078	0.4964	0.4504 ± 0.096	0.0574
Ridge (L2, $\alpha = 1.585$)	10	0.5185	0.4862	0.4597 ± 0.084	0.0587
Lasso (L1, $\alpha = 0.114$)	10	0.5185	0.4868	0.4577 ± 0.091	0.0608

Lecturas

No hay sobreajuste. La brecha entre entrenamiento y validación cruzada es de ~0.058 en las cuatro variantes: el modelo generaliza correctamente.

La regularización casi no cambia nada. Con 331 muestras y solo 10 variables, el modelo no tiene capacidad suficiente para memorizar los datos, de modo que Ridge y Lasso apenas mueven las métricas (± 0.003 en CV). Lasso anula una única variable, **s3** — coherente con que **s3** participa en la definición de **s4** y aporta poca información propia.

Este resultado es relevante para el Informe 2: la regularización aquí es **innecesaria**, pero se vuelve **imprescindible** al aplicarla sobre la expansión polinomial, donde el número de parámetros sí desborda a las muestras disponibles.

Eliminar **s1 y **s2** mejora el R² de prueba (0.4964)** pero empeora el de validación cruzada (0.4504). Como la CV es el criterio más fiable con 111 muestras de prueba, no se adopta como modelo final; sin embargo confirma que esas dos variables aportan poca información única, tal como anticipaba su VIF.

Modelo final: OLS con las 10 variables, por tener el mejor R² de validación cruzada (0.4606) y la interpretación más directa.

B.3 Significancia estadística de los coeficientes

Prueba t sobre los coeficientes del modelo OLS con las 10 variables estandarizadas ($gl = 331 - 11 = 320$):

Variable	Coefficiente	Error estándar	t	p-valor	Signif.
intercepto	154.3444	3.0142	51.21	< 0.0001	
age	2.2151	3.3234	0.67	0.5056	
sex	-11.5145	3.3670	-3.42	0.0007	
bmi	25.0770	3.7263	6.73	< 0.0001	
bp	18.2493	3.5898	5.08	< 0.0001	
s1	-44.1446	22.2102	-1.99	0.0477	*
s2	24.5139	17.9831	1.36	0.1738	
s3	5.4976	11.2118	0.49	0.6242	
s4	13.0068	9.2005	1.41	0.1584	
s5	33.3798	9.4361	3.54	0.0005	
s6	1.2480	3.6435	0.34	0.7322	

Significancia: \\ p < 0.001, \\ p < 0.01, \\ p < 0.05

Variables significativas al 5 %: **sex**, **bmi**, **bp**, **s1**, **s5**.

Confirmación numérica del diagnóstico de la Fase A

El patrón es inequívoco. Las variables **no significativas** (**s2**, **s3**, **s4**, **s6**, **age**) incluyen justamente las de **VIF más alto**, y sus errores estándar lo delatan:

Variable	VIF	Error estándar
s1	59.20	22.21
s2	39.19	17.98
s3	15.40	11.21
age	1.22	3.32
sex	1.28	3.37
bmi	1.51	3.73

Los errores estándar de las variables colineales son entre **5 y 7 veces mayores**. Eso es exactamente lo que produce la multicolinealidad: **infla la varianza de los estimadores**. El modelo detecta que el perfil lipídico influye, pero no puede repartir el crédito entre variables que se contienen unas a otras por definición.

Implicación práctica: los coeficientes lipídicos individuales **no deben interpretarse clínicamente**. El modelo sigue siendo válido para *predecir* — la multicolinealidad no sesga las predicciones — pero no para *explicar* el efecto aislado de **s1** o **s2**.

Los predictores clínicamente sólidos y estadísticamente limpios son **bmi** (+25.08), **s5** (+33.38), **bp** (+18.25) y **sex** (-11.51).




Figura. Peso de cada variable en el modelo

B.4 Diagnóstico de residuos




Figura. Diagnóstico de residuos del modelo lineal




Figura. Valores reales frente a valores predichos

Los residuos presentan distribución **aproximadamente normal** y **sin patrón estructural** frente a las predicciones. Esto valida los supuestos del modelo lineal e indica que el error restante es **ruido aleatorio, no sesgo sistemático sin capturar**.

Es un resultado importante: si los residuos mostraran curvatura, habría margen para un modelo no lineal. No la muestran — lo que anticipa el resultado del Informe 2.

B.5 Sobre la precisión alcanzada

Un R^2 de 0.485 puede parecer bajo. **No lo es para este problema**, y conviene argumentarlo con precisión:

1. **Límite intrínseco de los datos.** Solo 442 pacientes y 10 variables basales. La progresión de una enfermedad crónica depende de factores no medidos aquí: carga genética, tratamiento recibido, adherencia terapéutica, dieta, actividad física, comorbilidades.
2. **Referencia de la literatura.** El artículo que introdujo este dataset —Efron, Hastie, Johnstone y Tibshirani (2004), "*Least Angle Regression*"— trabaja en este mismo rango de ajuste. No es un resultado atípico.

3. El diagnóstico de residuos es correcto, como se documentó en B.4: el error restante es ruido, no estructura sin modelar.

4. Un R^2 alto sería sospechoso. Como se demuestra en el Informe 2, el modelo que alcanza $R^2 = 0.896$ en entrenamiento resulta ser el **peor de todos** al evaluarlo fuera de la muestra.

El modelo explica cerca de la mitad de la varianza de un fenómeno biológico complejo, con un error medio de ± 41.5 puntos sobre una escala de 25 a 346.

FASE C — Aplicativo web (modo Regresión Lineal Múltiple)

`index.html` + `model.js` — HTML y JavaScript puro, sin dependencias externas ni proceso de compilación.

`train.py` serializa el modelo en `model.js`: los parámetros de estandarización (μ_i , σ_i), los coeficientes β_i y el intercepto β_0 . El aplicativo reconstruye la predicción con la misma fórmula de la sección B.1.

Funcionalidades relevantes a este informe

- **Entrada dinámica** de las 10 variables basales mediante deslizadores acotados al rango real observado, sincronizados con campos numéricos. Predicción en tiempo real.
- **Cálculo paso a paso**: estandarización de cada variable, producto por su coeficiente, suma y adición del intercepto, con los números reales de la predicción.
- **Tabla de detalle** por variable con x_i , μ_i , σ_i , z_i , β_i y $\beta_i \cdot z_i$.
- **Tabla de VIF** de la Fase A.
- **Aviso** de que se trata de un ejercicio académico, no de una herramienta de diagnóstico clínico.

Verificación de paridad con scikit-learn

Caso de prueba	Python (scikit-learn)	JavaScript
Medianas del dataset	155.862491	155.8624910825692
Primer registro del set de prueba	137.949089	137.9490887781244
Perfil de riesgo alto	300.618775	300.6187747290852

Coincidencia con precisión de punto flotante.

Ejecución y despliegue

El archivo carga `model.js` mediante `<script src>`, que algunos navegadores bloquean bajo el protocolo `file://`. Servirlo por HTTP:

```
python -m http.server 8000
```

Para publicarlo basta con subir `index.html` y `model.js` a cualquier hosting estático (Netlify, GitHub Pages, Render). No requiere build ni servidor de aplicación.

Conclusiones — Regresión Lineal Múltiple

1. **El dataset es adecuado** para la metodología: variable objetivo continua, 10 predictores numéricos, sin nulos ni duplicados. Requiere `scaled=False` para poder aplicar el preprocesamiento exigido y construir una interfaz usable.
2. **La multicolinealidad es el hallazgo dominante** y es estructural: las variables lipídicas se contienen unas a otras por definición ($s_4 = s_1/s_3$, $s_2 \subset s_1$), con VIF de hasta 59.2. Su efecto se manifiesta como errores estándar entre 5 y 7 veces mayores en los coeficientes afectados, que en consecuencia **no son interpretables individualmente**.
3. **La regularización no mejora el ajuste**. Con 10 variables y 331 muestras el modelo no tiene margen para sobreajustar, de modo que Ridge y Lasso no cambian las métricas.
4. **El modelo final es OLS con las 10 variables**: R^2 de prueba 0.4849, R^2 de validación cruzada 0.4606 ± 0.085 , RMSE 53.37 y MAE 41.55. Los predictores más sólidos son `bmi`, `s5`, `bp` y `sex`.
5. **Los residuos validan el supuesto de linealidad**: distribución normal y sin patrón estructural. El error restante es ruido, no sesgo sistemático.
6. **La validación cruzada fue determinante**. Escogiendo por R^2 de prueba se habría seleccionado el modelo sin `s1,s2` (0.4964); la CV muestra que esa diferencia no supera el ruido de muestreo.

Referencias

1. Efron, B., Hastie, T., Johnstone, I. y Tibshirani, R. (2004). *Least Angle Regression*. **Annals of Statistics**, 32(2), 407–499. https://web.stanford.edu/~hastie/Papers/LARS/LeastAngle_2002.pdf
2. Pedregosa, F. *et al.* (2011). *Scikit-learn: Machine Learning in Python*. **Journal of Machine Learning Research**, 12, 2825–2830.
3. Documentación de scikit-learn — `sklearn.datasets.load_diabetes`. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_diabetes.html
4. James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning*, 2.^a ed. Springer. Capítulo 3: Regresión Lineal.
5. Montgomery, D. C., Peck, E. A. y Vining, G. G. (2021). *Introduction to Linear Regression Analysis*, 6.^a ed. Wiley. (Diagnóstico de multicolinealidad y VIF).
6. Fuente original de los datos: <https://www4.stat.ncsu.edu/~boos/var.select/diabetes.html>