

Clasificación Binaria de Potabilidad del Agua mediante Regresión Logística

Universidad Andina del Cusco — Escuela Profesional de Ingeniería de Sistemas

Curso: Inteligencia Artificial (2026-II) · **Docente:** Hugo Espetia Huamanga

Taller 1.2 — Práctica Calificada: Clasificación Binaria con Regresión Logística y Despliegue de Modelo

Integrantes:

Coavoy Cruz, Joseph Gabriel — [Código]

Cuchuyrrumi Mamani, Manuel Rodrigo — [Código]

Huallpatuiro Rafaile, Brayan — [Código]

Mamani Acuña, Frank Joseph — [Código]

Fecha: 02 de septiembre de 2026

Tabla de Contenido

Tabla de Contenido	2
1. Resumen Ejecutivo	3
2. Definición del Problema	3
3. Análisis Exploratorio y Preparación de Datos.....	3
4. Modelado con Regresión Logística.....	7
5. Resultados y Discusión de Métricas	9
6. Manual de Usuario y Arquitectura del Aplicativo	12
7. Conclusiones y Recomendaciones.....	13
8. Anexos	13

1. Resumen Ejecutivo

Este informe documenta el desarrollo de un clasificador binario de **potabilidad del agua** (potable / no potable) a partir de 9 parámetros fisicoquímicos, usando **Regresión Logística**. Se trabajó sobre el dataset público *Water Potability* (3276 muestras), aplicando imputación de valores faltantes, estandarización y una división estratificada 80/20 en entrenamiento y prueba. El modelo final, entrenado con `class_weight="balanced"` para compensar el desbalance de clases (61% no potable / 39% potable), obtiene en el conjunto de prueba una exactitud de **52.4%**, precisión de **41.5%**, sensibilidad de **53.1%**, F1-score de **46.6%** y un área bajo la curva ROC (AUC) de **0.547**. Estos resultados —apenas superiores al azar— indican que las 9 variables disponibles tienen una relación muy débil, y probablemente no lineal, con la potabilidad real del agua. El modelo se empaquetó como un pipeline `scikit-learn` serializado con `joblib` y se expuso mediante una aplicación web interactiva construida con **Streamlit**, lista para desplegarse en Streamlit Community Cloud.

2. Definición del Problema

El acceso a agua potable segura es un indicador crítico de salud pública. Confirmar la potabilidad de una muestra mediante ensayos de laboratorio completos es costoso y lento; un modelo que estime la potabilidad a partir de parámetros fisicoquímicos de rutina (pH, dureza, sólidos disueltos, cloraminas, sulfatos, conductividad, carbono orgánico, trihalometanos y turbidez) podría servir como una primera capa de *triage*: priorizar qué muestras requieren análisis de laboratorio urgente o alertar sobre posibles fuentes de agua no aptas para consumo.

El problema se plantea como una **clasificación binaria mutuamente excluyente**:

- **Clase 0 — No potable:** el agua no cumple los estándares de consumo humano.
- **Clase 1 — Potable:** el agua es apta para consumo humano.

Dataset: [Water Potability](#) (Kaggle), 3276 muestras y 9 variables predictoras, sin variables categóricas.


3. Análisis Exploratorio y Preparación de Datos

3.1 Calidad de los datos


Variable	Nulos	% del total
ph	491	15.0%
Sulfate	781	23.8%
Trihalomethanes	162	4.9%
(resto de variables)	0	0.0%

No se encontraron filas duplicadas. El desbalance de la variable objetivo es moderado:

Clase	Muestras	%
0 — No potable	1998	61.0%
1 — Potable	1278	39.0%




Balance de clases




Nulos por variable

3.2 Outliers y distribución

El análisis de outliers (método IQR, $1.5 \times \text{RIC}$) detecta valores atípicos en todas las variables, siendo Hardness (83), Chloramines (61) y Solids (47) las más afectadas; se optó por **no eliminarlos**, ya que en un problema de calidad de agua los valores extremos pueden ser señal real (contaminación, fuentes atípicas) y no necesariamente errores de medición.




Boxplots por variable



Histogramas por clase

3.3 Correlación con la variable objetivo

La matriz de correlación muestra que **ninguna variable individual tiene una relación lineal fuerte con `Potability`**: la correlación máxima en valor absoluto es apenas 0.034 (Solids). Esto anticipa que un modelo lineal como la regresión logística tendrá una capacidad predictiva limitada con estas variables.



3.4 Preprocesamiento

1. **Imputación de nulos:** SimpleImputer(strategy="median") para ph, Sulfate y Trihalomethanes, ajustado únicamente con el conjunto de entrenamiento para evitar fuga de información hacia el conjunto de prueba.
2. **Estandarización:** StandardScaler sobre las 9 variables numéricas (media 0, desviación 1), también ajustado solo con train.
3. **Codificación de variables categóricas:** no aplica — todas las variables son numéricas.
4. **División del dataset:** train_test_split 80/20 **estratificado** por Potability (justificado por el desbalance de clases), random_state=42. Resultado: **2620 muestras de entrenamiento** (1598 no potable / 1022 potable) y **656 de prueba** (400 no potable / 256 potable).

Todo el preprocesamiento se implementó dentro de un `sklearn.pipeline.Pipeline`, junto con el clasificador, para que el modelo serializado sea autocontenido y reciba datos crudos directamente desde la aplicación web.

4. Modelado con Regresión Logística

4.1 La función sigmoide

La regresión logística modela la probabilidad de la clase positiva aplicando la función **sigmoide** a una combinación lineal de las variables predictoras:

$$z = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \dots + \beta_9 \cdot x_9$$

$$\sigma(z) = 1 / (1 + e^{(-z)})$$

$\sigma(z)$ comprime cualquier valor real z al intervalo $(0, 1)$, interpretable como la probabilidad de que la muestra sea potable. Se clasifica como **Potable** si $\sigma(z) \geq 0.5$, y **No potable** en caso contrario.

4.2 Configuración del modelo

Hiperparámetro	Valor	Justificación
solver	lbfgs	Solver por defecto de scikit-learn, eficiente para datasets de este tamaño
penalty	l2	Regularización estándar para evitar sobreajuste
class_weight	balanced	El desbalance 61%/39% hacía que el modelo sin ajustar predijera siempre la clase mayoritaria (Precision/Recall/F1 = 0 para "Potable"); balancear los pesos corrige el umbral de decisión efectivo
max_iter	1000	Asegura convergencia del optimizador
random_state	42	Reproducibilidad


4.3 Análisis de coeficientes

Los coeficientes están en la escala estandarizada de las variables, por lo que son directamente comparables entre sí:

Variable	Coeficiente	Efecto
Solids	+0.0593	Aumenta la probabilidad de potabilidad
Chloramines	+0.0413	Aumenta la probabilidad de potabilidad
Organic_carbon	-0.0286	Reduce la probabilidad de potabilidad
ph	+0.0256	Aumenta la probabilidad de potabilidad
Sulfate	-0.0133	Reduce la probabilidad de potabilidad
Trihalomethanes	+0.0082	Aumenta la probabilidad de

		potabilidad
Conductivity	+0.0061	Aumenta la probabilidad de potabilidad
Turbidity	+0.0024	Aumenta la probabilidad de potabilidad
Hardness	-0.0021	Reduce la probabilidad de potabilidad

Intercepto: -0.0007



Coeficientes del modelo

La magnitud de todos los coeficientes es muy pequeña (< 0.06), consistente con las correlaciones casi nulas observadas en el EDA: ninguna variable domina la predicción, y el modelo en conjunto captura muy poca señal.

5. Resultados y Discusión de Métricas

Todas las métricas se calcularon sobre el **conjunto de prueba** (656 muestras, no vistas durante el entrenamiento).


5.1 Matriz de confusión

	Predicho: No potable	Predicho: Potable
Real: No potable	TN = 208	FP = 192

Real: Potable

FN = 120


TP = 136



Matriz de confusión

5.2 Métricas de desempeño

Métrica	Valor
Accuracy	52.4%
Precision	41.5%
Recall (Sensibilidad)	53.1%
F1-Score	46.6%
AUC-ROC	0.547



Curva ROC

5.3 Interpretación operativa de los errores


La curva ROC está muy cerca de la diagonal de azar (AUC = 0.547), confirmando que el modelo apenas mejora una predicción aleatoria. En el contexto de potabilidad del agua, los dos tipos de error tienen **costos muy distintos**:

- **Falsos Negativos (FN = 120)**: agua realmente potable clasificada como no potable. El costo es principalmente **operativo**: se descarta o se reanaliza innecesariamente una fuente de agua segura.
- **Falsos Positivos (FP = 192)**: agua realmente no potable clasificada como potable. El costo es de **salud pública**, mucho más grave: se podría distribuir o consumir agua contaminada creyendo que es segura.

En este modelo, FP (192) > FN (120): el ajuste por `class_weight="balanced"` mejoró la sensibilidad hacia la clase "Potable" pero, como contrapartida, aumentó los falsos positivos — precisamente el error más peligroso en este dominio. Esto sugiere que, antes de cualquier uso operativo real, debería ajustarse el **umbral de decisión** (por encima de 0.5) para privilegiar la detección de agua no potable, aun a costa de accuracy global, o explorar modelos con mejor capacidad discriminativa (ver Conclusiones).

6. Manual de Usuario y Arquitectura del Aplicativo

6.1 Arquitectura



El modelo se entrena y evalúa en `train_model.py`, que exporta `modelo_potabilidad.pkl` (pipeline completo, autocontenido) y `resultados_metricas.json` (métricas y metadatos que la app también consume para mostrar su propio desempeño). La aplicación `app.py` es un frontend Streamlit sin estado de servidor adicional: cada predicción se calcula en el momento a partir del pipeline cargado en memoria.

6.2 Manual de uso

1. Abrir la URL pública de la aplicación (ver sección 6.3).
2. En la pestaña "🧠 **Predecir**", completar los 9 campos con los parámetros fisicoquímicos de la muestra de agua (los campos vienen precargados con la mediana de cada variable como valor de referencia).
3. Presionar "**Predecir potabilidad**".
4. La aplicación muestra la clase predicha (✅ Potable / ❌ No potable) junto con la probabilidad estimada.
5. En la pestaña "📊 **Métricas del modelo**" puede consultarse el desempeño del modelo sobre el conjunto de prueba (accuracy, precision, recall, F1, AUC, matriz de confusión y coeficientes).

La aplicación fue verificada localmente (`streamlit run app.py`) con casos reales del dataset, incluyendo una muestra potable (predicha correctamente como Potable, 53.0% de probabilidad) y con los valores por defecto (mediana de cada variable, predicha como No potable, 49.8% de probabilidad).

6.3 Despliegue

URL pública: [pendiente de despliegue]

La aplicación está lista para desplegarse en **Streamlit Community Cloud**, conectada al repositorio de GitHub (`requirements.txt` y `app.py` en TALLER 1.2/). El despliegue queda pendiente de que el equipo conecte su cuenta de GitHub en share.streamlit.io; una vez publicada, esta sección debe actualizarse con la URL final y capturas de pantalla de la versión en producción.

7. Conclusiones y Recomendaciones

- El modelo de regresión logística alcanza un desempeño apenas superior al azar (AUC = 0.547, Accuracy = 52.4%), lo que indica que las 9 variables fisicoquímicas disponibles en este dataset tienen una relación débil —y probablemente no lineal— con la potabilidad real medida en laboratorio. Esta limitación ya era visible en el EDA: ninguna variable individual supera $|r| = 0.034$ de correlación con el target.
- El ajuste por `class_weight="balanced"` fue necesario para obtener un clasificador que efectivamente distinga ambas clases (sin él, el modelo predecía siempre "no potable"), pero desplazó el error hacia más falsos positivos, el tipo de error más costoso en este dominio.
- **Recomendaciones para trabajo futuro:**
 1. Evaluar modelos no lineales (Random Forest, Gradient Boosting, SVM con kernel RBF) que puedan capturar interacciones entre variables no accesibles a un modelo lineal.
 2. Incorporar ingeniería de atributos (razones e interacciones entre variables, p. ej. pH × Cloraminas).
 3. Ajustar el umbral de decisión de forma explícita para minimizar falsos positivos, dado el costo asimétrico de los errores en salud pública.
 4. De ser posible, ampliar el dataset con variables adicionales (indicadores bacteriológicos, metales pesados) que suelen tener mayor poder predictivo sobre la potabilidad real.

8. Anexos

- **Repositorio de código:** github.com/JigSaw1117/CLAUDIOS — carpeta TALLER 1.2/.
- **Dataset original:** [Water Potability — Kaggle](https://www.kaggle.com/datasets/water-potability).
- **Archivos del proyecto:** `train_model.py` (entrenamiento), `app.py` (aplicativo Streamlit), `modelo_potabilidad.pkl` (modelo serializado), `resultados_metricas.json` (métricas completas), `figuras/` (gráficos del EDA y la evaluación).